



FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA

**DISRUPTIVE ARCHITECTURES: IOT, IOB & GENERATIVE IA
SPRINT 3**

**IASI – INTELIGENCIA ARTIFICIAL DE SUSTENTABILIDADE
INDÚSTRIAL**

MARY ARAÚJO MOREIRA SPERANZINI - RM550242

EDUARDO JABLINSKI - RM550975

CAIO RIBEIRO – RM 99759

ELEN CABRAL - RM98790

GUILHERME RIOFRIO - RM550138

SUMÁRIO

INTRODUÇÃO.....	3
PROTÓTIPOS E MODELOS.....	4
ARQUITETURA DETALHADA E JUSTIFICATIVA.....	5-7
BASES DE DADOS.....	8
CONCLUSÃO.....	9

INTRODUÇÃO

SÃO PAULO
2023

Este documento tem como objetivo apresentar o progresso do projeto IASI (Inteligência de Avaliação de Sustentabilidade Industrial) e ilustrar suas etapas evolutivas. O IASI busca transformar a gestão industrial através do uso de tecnologias avançadas em Machine Learning e Inteligência Artificial. Nesta fase, o foco está em demonstrar o protótipo e em analisar detalhadamente a arquitetura de IA que sustentará as futuras implementações.

Vamos explorar as funcionalidades do protótipo, as decisões tecnológicas tomadas e como essas escolhas foram implementadas para atender aos desafios específicos da indústria.

PROTÓTIPOS E MODELOS

Desenvolvemos três modelos distintos, cada um focado em uma área crítica da operação industrial:

Consumo energético

Utilizando uma rede neural convolucional (CNN) para analisar dados históricos de consumo de energia e prever demandas futuras, esse modelo integra informações sobre condições operacionais e variáveis externas, como clima, para otimizar o uso da energia e reduzir custos.

Treinado com dados de consumo passados e variáveis operacionais, o modelo identifica padrões e faz previsões sobre a demanda energética, ajudando a ajustar a produção e evitar desperdícios.

Manutenção industrial

Prevê falhas em equipamentos com base em dados de sensores e histórico de manutenção. Utilizando técnicas de Machine Learning, ele detecta sinais de desgaste iminente e permite uma manutenção proativa.

Nosso objetivo futuro é analisar dados provenientes de sensores físicos, para que o modelo emita alertas para ações de manutenção antes que ocorra uma falha crítica, minimizando o tempo de inatividade inesperado.

Gestão inteligente

Classifica resíduos em diferentes categorias usando uma CNN treinada com imagens. Ele facilita a separação e o tratamento adequado dos resíduos, promovendo práticas de reciclagem e gestão ambiental responsável em ambientes industriais.

Processa imagens de resíduos para identificar e classificar tipos como papel, vidro e plástico, ajudando na gestão eficiente e sustentável dos resíduos.

Nossa proposta de solução pretende melhorar a eficiência operacional das fábricas e promover práticas sustentáveis, oferecendo insights baseados em dados para otimização e gestão eficaz

ARQUITETURA DETALHADA E JUSTIFICATIVA

Otimização de Consumo de Energia Elétrica:

Modelo Utilizado: Rede Neural Densa (DNN) com camadas totalmente conectadas.

Arquitetura do Modelo:

Entrada: Camada de entrada com 10 neurônios para receber variáveis de entrada como consumo histórico, temperatura, umidade e ocupação.

Camadas Ocultas: Duas camadas ocultas com 64 e 32 neurônios, respectivamente, usando a função de ativação ReLU para introduzir não-linearidades.

Saída: Camada de saída com um único neurônio para prever o consumo de energia, utilizando a função de ativação linear.

Regularização: Dropout com taxa de 0.2 para evitar overfitting.

Resultados: O modelo é avaliado usando erro quadrático médio (MSE) e erro médio absoluto (MAE). As previsões são comparadas com os valores reais em gráficos para análise visual.

Nessa funcionalidade, optamos por utilizar TensorFlow e Keras para implementar uma Rede Neural Densa (DNN). A escolha dessa arquitetura é fundamentada na sua capacidade de analisar dados numéricos extensivos e complexos, como o histórico de consumo e condições climáticas, fornecidos pelo dataset “Energy Consumption Prediction” do Kaggle. A DNN é ideal para aprender relações não lineares e padrões ocultos nos dados, possibilitando previsões precisas do consumo de energia. Isso contribui para a otimização do uso energético e redução de custos operacionais, aspectos críticos para a eficiência energética em ambientes industriais.

Manutenção Preditiva de Equipamentos:

Modelo Utilizado: Rede Neural Densa (DNN) para classificação binária.

Arquitetura do Modelo:

Entrada: Camada de entrada com 12 neurônios para dados de sensores, como temperatura do equipamento e velocidade rotacional.

Camadas Ocultas: Duas camadas ocultas com 64 e 32 neurônios, usando ReLU como função de ativação.

Saída: Camada de saída com um neurônio e função de ativação sigmoid para prever a probabilidade de falha.

Regularização: Dropout e normalização de lote (Batch Normalization) para melhorar a generalização.

Resultados: O desempenho do modelo é medido por precisão, recall e a área sob a curva ROC (AUC-ROC). A importância das características é avaliada para interpretar quais sensores mais contribuem para a previsão de falhas.

Para este segundo modelo, que foi desenvolvido com TensorFlow, utilizamos uma Rede Neural Convolutiva (CNN) adaptada para análise de dados temporais provenientes de sensores. Essa escolha se deve à capacidade da CNN de extrair e interpretar padrões complexos e características temporais nos sinais dos sensores. A arquitetura CNN é particularmente eficaz em reconhecer padrões sutis que precedem falhas de equipamentos, permitindo a implementação de estratégias de manutenção proativa. Essa abordagem ajuda a evitar interrupções inesperadas e melhora a eficiência operacional.

Gestão e Classificação de Resíduos:

Modelo Utilizado: Rede Neural Convolutiva (CNN) para classificação de imagens.

Arquitetura do Modelo:

Entrada: Imagens redimensionadas para 224x224 pixels.

Camadas Convolucionais: Três camadas convolucionais com 32, 64 e 128 filtros, respectivamente, seguidas por camadas de pooling para redução dimensional.

Camadas Densas: Duas camadas densas com 128 e 64 neurônios, usando ReLU como função de ativação.

Saída: Camada de saída com um neurônio por classe (12 classes) e função de ativação softmax para classificação multiclasse.

Resultados: Avaliado usando acurácia, precisão, recall e F1-score. As previsões são visualizadas com imagens e suas classes previstas.

Por último, para uma gestão inteligente e sustentável, para a classificação de resíduos desenvolvemos um modelo com Keras e treinamos ele com mais de 2.000 imagens e uma arquitetura de Rede Neural Convolucional (CNN). Optamos pela CNN devido à sua notável eficácia na identificação e classificação de padrões visuais em imagens, como texturas e formas, essenciais para a classificação precisa dos resíduos. A CNN proporciona uma solução eficiente para a triagem automatizada de resíduos, facilitando a gestão e a reciclagem eficiente de materiais.

BASES DE DADOS (IN DEPTH)

Consumption Prediction Dataset

Esta base de dados contém variáveis como consumo de energia, condições climáticas, e padrões de produção, que são essenciais para treinar o modelo de previsão de consumo de energia. Os dados foram utilizados para identificar padrões e prever futuras demandas energéticas, permitindo a otimização do consumo e a redução de custos.

Fonte: <https://www.kaggle.com/datasets/mrsimple07/energy-consumption-prediction>

Machine Predictive Maintenance Classification Dataset

Esta base de dados inclui registros de falhas e condições operacionais de equipamentos, coletados a partir de sensores. É fundamental para o modelo de manutenção preditiva, que analisa os dados para identificar padrões que antecedem falhas de equipamentos.

Fonte: <https://www.kaggle.com/datasets/shivamb/machine-predictive-maintenance-classification>

Garbage Classification Dataset

Por último, utilizamos esses dados para treinar o modelo de gestão e classificação de resíduos, permitindo a identificação precisa e a categorização de diferentes tipos de lixo. Ele contribui para a redução do impacto ambiental e melhorando a eficiência na reciclagem.

Fonte: <https://www.kaggle.com/datasets/mostafaabla/garbage-classification>

CONCLUSÃO

A integração desses três modelos no protótipo funcional do IASI evidencia a aplicação eficaz de técnicas avançadas de Machine Learning para enfrentar desafios específicos do setor industrial. Cada modelo foi desenvolvido com rigor técnico para oferecer soluções robustas e adaptáveis, garantindo não apenas a otimização dos processos industriais, mas também promovendo práticas mais sustentáveis. A precisão e a eficiência alcançadas nos nossos testes demonstram a capacidade do projeto de impactar positivamente a operação industrial e o meio ambiente.